

INGENIERÍA EN DESARROLLO Y TECNOLOGÍAS DE SOFTWARE

[Proyecto Final, Enero-Junio 2026]

Título del proyecto: “Análisis predictivo de la producción de azúcar en México mediante regresión lineal y procesamiento ETL con datos abiertos de Infocaña”

Propósito: Desarrollar en el estudiante la capacidad de aplicar técnicas de análisis de datos a gran escala, integrando procesos de **extracción, transformación y carga (ETL)** junto con modelos de **regresión lineal básica**, para generar predicciones en un contexto real del sector agroindustrial; con la finalidad de generar un pronóstico para ciertos patrones de comportamiento que coadyuven al proceso de toma de decisiones; para ello, se desarrollara un Dashboard de indicadores utilizando técnicas de visualización de datos, el framework Shiny for Python y el repositorio Github pages.

Construir un modelo de regresión lineal en Python que permita **predecir la producción total de azúcar** en función de variables operativas (como caña molida o superficie cosechada), utilizando datos históricos del sistema Infocaña efectuando un concentrado de los datasets de 2015-2026, previamente procesados mediante un script pipeline ETL.

El conjunto de datos se encuentra disponible para su descargar de manera libre en el siguiente repositorio de datos abiertos del Gobierno de México:

https://www.datos.gob.mx/dataset/avance_produccion_cana_azucar_infocana

The screenshot shows the dataset page for 'Avance de la producción de...' on the datos.gob.mx portal. The page includes the CONADESUCA logo and name, a description of the organization, and social media links. The main content area displays the dataset title, a brief description, and a 'Consultar' button. A warning message indicates that some data may include retroactive updates.

CONADESUCA
Comité Nacional para el Desarrollo Sustentable de la Caña de Azúcar (CONADESUCA)

Organismo público descentralizado de la Administración Pública Federal, su misión es generar información completa, veraz y oportuna de la agroindustria de la caña de azúcar...

[leer más](#)

Social

- ☒ Twitter
- ☐ Facebook

Licencia

Creative Commons Attribution 4.0 [ver más](#)

Base de datos Categorías

Información estadística de los principales indicadores de producción, que se generan en los informes oficiales de corrida de fábrica de los ingenios azucareros.

Bases de datos

Algunas bases de datos pueden incluir actualizaciones retroactivas por lo que la información histórica puede cambiar en actualizaciones posteriores.

Información estadística de los principales...

Datos de producción de la caña de azúcar 2025-2026. Incluye nombre del ingenio azucarero, cantidades de caña molida, superficie cosechada, total de azúcar producida, totales de...

Categoría: Agricultura

Formatos: CSV

Institución: Comité Nacional para el Desarrollo Sustentable de la Caña de Azúcar (CONADESUCA)

[Consultar](#) [Descargar](#)

Información estadística de los principales...

Datos de producción de la caña de azúcar 2024-2025. Incluye nombre del ingenio azucarero, cantidades de caña molida, superficie cosechada, total de azúcar producida, totales de...

En virtud que el conjunto de datos posee registros históricos del periodo 2015 a 2026 con una frecuencia mensual, es pertinente para construir una **serie temporal** (variable independiente: tiempo/zafra); así también, posee variables continuas ideales para regresión:

- Producción vs superficie
- Producción vs caña molida

Zafra: es el periodo anual de **cosecha y recolección de la caña de azúcar**, así como el proceso posterior de fabricación de azúcar y etanol en los ingenios.

Paso 1.- Considerar los siguientes criterios para realizar el análisis de datos:

Serie temporal (variable independiente: tiempo/zafra)

Variable recomendada para regresión lineal

- **Variable dependiente (Y):** azúcar_producida_total
- **Variable independiente (X):**
caña_molida_neta (mejor relación lineal esperada) o superficie_cosechada.

Es necesario realizar el correcto ajuste o calibración del modelo Series de tiempo, para realizar un correcto pronóstico; y considerar la división del conjunto de datos para entrenamiento 80% y pruebas 20%.

Metodología del proyecto

1. ETL (Extract, Transform, Load)

Extract (Extracción):

- Descarga de archivos CSV desde datos.gob.mx (2015-2026)
- Integración de múltiples zafras en un solo dataset

Transform (Transformación):

- Limpieza de datos:
 - Eliminación de valores nulos
 - Normalización de nombres de columnas
- Conversión de tipos de datos
- Generación de variables derivadas:
 - Ej. rendimiento promedio por ingenio
- Agregación por año/zafra

Load (Carga):

- Almacenamiento en:
 - DataFrame de Pandas
 - O base de datos (opcional: SQLite)

Modelado: Regresión Lineal

Modelo:


- Regresión lineal simple:

$$Y = \beta_0 + \beta_1 X$$

Ejemplo:

- Y : azúcar producida total
- X : caña molida neta

Paso 2.- Mockup del Dashboard de Visualización de Datos (Shiny for R or Python)



Para diseñar el Dashboard dinámico, se sugiere preferentemente utilizar el framework Shiny y ShinyLive optando por el lenguaje de programación R o Python; el cual debe visualizar el conjunto de datos en un componente DataTable, visualizar la aplicación del algoritmo Series de tiempo mediante un componente Plot y la biblioteca sklearn, con sus respectivos controles de manipulación de entrada de datos.

Paso 3.- Interpretación de Dashboard para toma de decisiones

Analiza el comportamiento de los datos aplicando los modelos de aprendizaje supervisado, y da respuesta a los siguientes cuestionamientos.

Cuestionamientos relacionados con la aplicación del modelo de pronósticos:

1. ¿En qué medida la cantidad de caña molida neta permite predecir la producción total de azúcar en los ingenios durante una zafra, y cuál es la relación funcional entre ambas variables?
- 2.- ¿Cómo ha cambiado la producción total de azúcar a lo largo de las zafras y cuánto podría producirse en la próxima zafra (anual) si la tendencia continúa?

Productos Entregables:

- Informe del proyecto final en formato .pdf
- Dashboard (Shiny) para visualización de datos
- URL del repositorio Github pages (Despliegue de la aplicación)

EQUIPO: Integrado por un máximo de 2 estudiantes.

Nota: Es obligatorio desplegar la aplicación en el hosting web de github.

El **Informe final** deberá contener:

- Hoja de presentación (nombre del proyecto, estudiantes, fecha, etc.)
- Introducción
- Código del proyecto y URL del repositorio Github Pages
- Resultados (Captura de pantallas del funcionamiento)
- Interpretación de resultados y cuestionamientos del caso de estudio.

FECHA DE ENTREGA Y PRESENTACIÓN: **12 DE MAYO DE 2026**

Referencias y tutoriales:

<https://github.com/posit-dev/py-shiny-templates/tree/main/dashboard>

<https://aneesha.medium.com/timeseries-forecasting-with-the-forecast-r-package-and-shiny-6fa04c64196>

<https://shiny.posit.co/py/gallery/>

https://medium.com/@robinvisser_27509/tim-time-series-insights-maker-r-shiny-9f6eaf0ec1e7

<https://github.com/ilsep93/Shiny-Forecasting>

Dr. Christian Mauricio Castillo Estrada <cmce@unach.mx>

Profesor de tiempo completo

Ingeniería en Desarrollo y Tecnologías de Software

Facultad de Negocios Campus IV UNACH